

Министерство науки и высшего образования Российской Федерации Федеральное государственное бюджетное образовательное учреждение высшего образования

«Московский государственный технический университет имени Н.Э. Баумана

(национальный исследовательский университет)» (МГТУ им. Н.Э. Баумана)

(MII 10 MM. II. 9. Daymana)		
	Информатика и системы управления Системы обработки информации и управления	
	Отчет по лабораторной работе №3 «Обработка пропусков в данных, одирование категориальных признаков, масштабирование данных» курсу «Технологии машинного обучения»	
	Выполнил: Студент группы ИУ5Ц-81Б Тураев Глеб	
	Проверил: Преподаватель кафедры ИУ5 Гапанюк Ю.Е.	

Цель лабораторной работы: Изучение способов предварительной обработки данных для дальнейшего формирования моделей.

Задание:

- 1. Выбрать набор данных (датасет), содержащий категориальные признаки и пропуски в данных. Для выполнения следующих пунктов можно использовать несколько различных наборов данных (один для обработки пропусков, другой для категориальных признаков и т.д.)
- 2. Для выбранного датасета (датасетов) на основе материалов лекции решить следующие задачи:
 - обработку пропусков в данных;
 - кодирование категориальных признаков;
 - масштабирование данных.

Выполнение лабораторной работы:

Был выбран следующий датасет: https://www.kaggle.com/lava18/google-play-store-apps

1. Текстовое описание данных

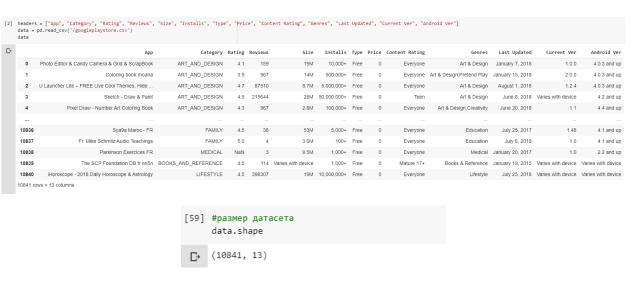
- Арр название приложения
- Category категория, к которой относится приложение
- **Rating** общий рейтинг пользователя приложения
- **Reviews** количество отзывов пользователей для приложения
- **Size** размер приложения
- **Installs** количество загрузок/установок пользователем приложение
- **Type** платное или бесплатное
- **Price** цена приложения
- Content Rating возрастное ограничение
- **Genres** жанр игры
- Last Updated- дата последнего обновления приложения в Play Store
- Current Ver текущая версия приложения, доступная в Play Store
- Android Ver минимальная требуемая версия Android

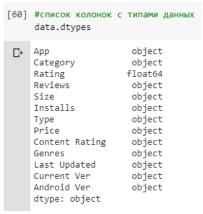
2. Импортируем библиотеки:

Осуществим импорт библиотек с помощью команды import:

```
[1] import numpy as np
  import pandas as pd
  import seaborn as sns
  import matplotlib.pyplot as plt
  %matplotlib inline
  sns.set(style="whitegrid")
```

- /usr/local/lib/python3.6/dist-packages/statsmodels/tools/_
 import pandas.util.testing as tm
- 3. Осуществим загрузку датасета, выведем таблицу и проведем анализ:





```
[61] #проверка на пропуски в датасете
  data.isnull().sum()
App
    Category
                       0
    Rating
                    1474
    Reviews
                       0
    Size
                       0
    Installs
    Type
    Price
    Content Rating
                      1
    Genres
                       0
    Last Updated
                       0
    Current Ver
    Android Ver
    dtype: int64
```

4. Обработка пропусков

4.1. Простая стратегия – удаление или заполнение нулями

```
[62] #удаление колонок, содержащих пустые значения
                                                                                                                                                            data_new_1 = data.dropna(axis=1, how='any')
                                                                                                                                                           (data.shape, data_new_1.shape)
                                                                                                                                           [63] #удаление строк, содержащих пустые значения
                                                                                                                                                         data new 2 = data.dropna(axis=0, how='any')
                                                                                                                                                         (data.shape, data_new_2.shape)

¬→ ((10841, 13), (9360, 13))

          г
                                                                                                                                                                                                                          19M 10,000+ Free 0 Everyone Art & Design January 7, 2018 1.0.0 4.0.3 and up
                     Photo Editor & Candy Camera & Grid & ScrapBook ART_AND_DESIGN 4.1 159
                                                                                                                                    ART_AND_DESIGN
          1 Coloming Dook Modals ART_AND_DESIGN 3.9 907 14M 300,000+ Free 0 Everyone Art & Design August 1, 2018 12.4 4.0 3 and up 2 U Launcher Life - FREE Live Cool Themes, Hide ... ART_AND_DESIGN 4.7 87510 8.7M 5,000,000+ Free 0 Everyone Art & Design August 1, 2018 12.4 4.0 3 and up 3 and 
                                                                                                                                    ART_AND_DESIGN
                                                                                                                                                                                4.5 215644
                                                                                                                                                                                                                                     25M 50,000,000+ Free
                                                                                                                                                                                                                                                                                                                                                                                              June 8, 2018 Varies with device
          4 Pixel Draw - Number Art Coloring Book ART_AND_DESIGN 4.3 967 2.8M 100,000+ Free 0 Everyone Art & Design, Creativity June 20, 2018 1.1 4.4 and up

        10836
        Sya9a Maroc - FR
        FAMILY
        4.5
        3.8
        53M
        5,000+
        Free
        0
        Everyone
        Education
        July 25, 2017
        1.48
        4.1 and up

           10837
                                                      Fr Mike Schmitz Audio Teachings
                                                                                                                                                        FAMILY
                                                                                                                                                                                                                                   3.6M
                                                                                                                                                                                                                                                            100+ Free
                                                                                                                                                                                                                                                                                                                 Everyone
                                                                                                                                                                                                                                                                                                                                                                 Education
                                                                                                                                                                                                                                                                                                                                                                                               July 6 2018

        19837
        Fr. Miles Schmitz Audio Teachings
        FAMILY
        5.0
        4
        3.6M
        100+ Free
        0
        Everyone
        Education
        July 6, 2018
        1.0
        4.1 and up

        10838
        The SCP Foundation DB rnn5n
        MCDIAL
        0.0
        3
        9.5M
        1,000+ Free
        0
        Everyone
        Education
        July 6, 2018
        1.0
        2.2 and up

        10839
        The SCP Foundation DB rnn5n
        BOOKS_AND_REFERENCE
        4.5
        114
        Varies with device
        1,000+ Free
        0
        Mature 17+
        Books & Reference
        January 19, 2015
        Varies with device
        Varies with device
        1,000+ Free
        0
        Mature 17+
        Books & Reference
        January 19, 2015
        Varies with device
        Varies with device
        1,000+ Free
        0
        Mature 17+
        Books & Reference
        January 19, 2015
        Varies with device
        Varies with device
        1,000+ Free
        0
        Mature 17+
        Books & Reference
        January 19, 2015
        Varies with device
        Varies with device
        1,000+ Free
        0
        Mature 17+
        Books & Reference
        January 19, 2015
        Varies with device
        1,000+ Free
        0
        Mature 17+
        Books
           10840 IHoroscope - 2018 Daily Horoscope & Astrology LIFESTYLE 4.5 398307 19M 10,000,000+ Free 0 Everyone Lifestyle July 25, 2016 Varies with device Varies with device
          10841 rows × 13 columns
```

4.2. Импьютация

4.2.1. Обработка пропусков в числовых данных

```
#Выберем числовые колонки с пропущенными значениями

#цикл по колонкам датасета
num_cols = []

for col in data.columns:
    temp_null_count = data [data[col].isnull()].shape[0]
    dt = str(data[col].dtype)
    if temp_null_count > 0 and (dt == 'float64' or dt == 'int64'):
        num_cols.append(col)
        temp_perc = round((temp_null_count / total_count) * 100.0, 2)
        print('Колонка {}. Тип данных {}. Количество пустых значений {}, {}%'.format(col, dt, temp_null_count, temp_perc))

Колонка Rating. Тип данных float64. Количество пустых значений 1474, 13.6%
```

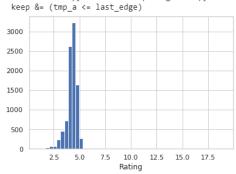
[67] #фильтр по колонкам с пропущенными значениями data num = data[num cols] data_num

₽		Rating
	0	4.1
	1	3.9
	2	4.7
	3	4.5
	4	4.3
	10836	4.5
	10837	5.0
	10838	NaN
	10839	4.5
	10840	4.5

10841 rows x 1 columns

```
[68] #гистограмма по признакам
     for col in data_num:
         plt.hist(data[col], 50)
         plt.xlabel(col)
         plt.show()
```

() /usr/local/lib/python3.6/dist-packages/numpy/lib/histograms.py:839: RuntimeWarning: invalid value encountered in greater_equal keep = (tmp_a >= first_edge)
/usr/local/lib/python3.6/dist-packages/numpy/lib/histograms.py:840: RuntimeWarning: invalid value encountered in less_equal



[69] #фильтр по пустым значениям поля Rating data[data['Rating'].isnull()]

```
App
                                         Category Rating Reviews Size Installs Type Price Content Rating
                                                                                                                           Last Updated Current Ver Android Ver
          Mcqueen Coloring pages
 23
                                  ART_AND_DESIGN NaN 61 7.0M 100,000+ Free 0 Everyone Art & Design; Action & Adventure
                                                                                                                          March 7, 2018 1.0.0 4.1 and up
            Wrinkles and rejuvenation
                                        BEAUTY NaN
                                                        119 3.7M 50,000+ Free 0 Everyone
                                                                                                                           July 23, 2018 1.3 4.1 and up
 123
            Manicure - nail design
                                                                                                                Beauty
 126
         Skin Care and Natural Beauty
                                         BEAUTY
                                                  NaN
                                                          654 7.4M 100.000+ Free
                                                                                            Teen
                                                                                                                            July 17, 2018
                                                                                                                                            1.15
                                     BEAUTY NaN 77 2.9M 10,000+ Free 0 Mature 17+
                                                                                                                        August 8, 2017 2.0 2.3 and up
 129 Secrets of beauty, youth and health
10824
                                        MEDICAL NaN 67 82M 10,000+ Free 0
                                                                                                                Medical July 31, 2018 2.2.2 4.4 and up
                                                           7 7.7M
               Naruto & Boruto FR
                                                                                                                                            1.0 4.0 and up
         payermonstationnement.fr MAPS AND NAVIGATION NAN
                                                                                                          Maps & Navigation June 13, 2018 2.0.148.0 4.0 and up
10831
                                                          38 9.8M 5,000+ Free 0
                                                                                        Everyone
10835
                     FR Forms
                                        BUSINESS
                                                  NaN
                                                           0 9.6M
                                                                      10+ Free
                                                                                         Everyone
                                                                                                                Business September 29, 2016
                                                                                                                                           1.1.5
                                                                                                                                                 4.0 and up
10838
         Parkinson Exercices FR MEDICAL NaN 3 9.5M 1,000+ Free 0 Everyone
                                                                                                              Medical January 20, 2017 1.0 2.2 and up
1474 rows × 13 columns
```

```
[70] #запоминаем индексы строк с пустыми значениями
     flt_index = data[data['Rating'].isnull()].index
     flt_index
 Int64Index([ 23,
                      113, 123, 126, 129, 130, 134, 163,
                 185,
                10816, 10818, 10821, 10822, 10823, 10824, 10825, 10831, 10835,
               dtype='int64', length=1474)
```

```
[71] #проверим, что выводятся нужные с data[data.index.isin(flt_index)]
Ľ÷
                           App
                                          Category Rating Reviews Size Installs Type Price Content Rating
                                                                                                               Genres
                                                                                                                        Last Updated Current Ver Android Ver
               Mcqueen Coloring pages
                                    ART_AND_DESIGN NaN
                                                         61 7.0M 100,000+ Free 0 Everyone Art & Design; Action & Adventure
                                                                                                                        March 7, 2018 1.0.0 4.1 and up
     113
               Wrinkles and rejuvenation
                                           BEAUTY
                                                    NaN
                                                           182 5.7M 100.000+ Free
                                                                                      Everyone 10+
                                                                                                               Beauty September 20, 2017
     123
                Manicure - nail design
                                           BEAUTY NaN 119 3.7M 50,000+ Free 0 Everyone
                                                                                                                      July 23, 2018
     126
             Skin Care and Natural Beauty
                                                           654 7.4M 100,000+ Free
                                                                                                                         July 17, 2018
                                          BEAUTY NaN 77 2.9M 10,000+ Free 0
     129 Secrets of beauty, youth and health
                                                                                       Mature 17+
                                                                                                               Beauty
                                                                                                                        August 8, 2017
    10824
                      Cardio-FR MEDICAL NaN
                                                          67 82M 10,000+ Free 0 Everyone
                                                                                                             Medical
                                                                                                                      July 31, 2018 2.2.2 4.4 and up
    10825
                   Naruto & Boruto FR
                                           SOCIAL
                                                   NaN
                                                            7 7.7M
                                                                     100+ Free
                                                                                           Teen
                                                                                                               Social
                                                                                                                      February 2, 2018
                                                                    5,000+ Free 0
    10831
               payermonstationnement.fr MAPS AND NAVIGATION NaN
                                                            38 9.8M
                                                                                                        Maps & Navigation June 13, 2018
     10835
                                          BUSINESS
                                                    NaN
                                                            0 9.6M
                                                                      10+ Free
                                                                                        Everyone
                                                                                                              Business September 29, 2016
                                        MEDICAL NaN 3 9.5M 1,000+ Free 0
                                                                                                             Medical January 20, 2017 1.0 2.2 and up
    10838
             Parkinson Exercices FR
                                                                                        Everyone
    1474 rows × 13 columns
                                       [72] #фильтр по колонке
                                              data_num[data_num.index.isin(flt_index)]['Rating']
                                            23
                                                        NaN
                                         Ľ÷
                                              113
                                                        NaN
                                              123
                                                        NaN
                                              126
                                                        NaN
                                              129
                                                        NaN
                                              10824
                                                        NaN
                                              10825
                                                        NaN
                                              10831
                                                        NaN
                                              10835
                                                        NaN
                                              10232
                                                       NaN
                                              Name: Rating, Length: 1474, dtype: float64
                                               [73] data_num_Rating = data_num[['Rating']]
    data_num_Rating.head()
                                                Гэ
                                                     0 4.1
                                                     1
                                                           39
                                                           4.7
                                                     3
                                                           4.5
                                                     4 4.3
                                               [74] from sklearn.impute import SimpleImputer
                                                     from sklearn.impute import MissingIndicator
                                [75] #фильтр для проверки заполнения пустых значений
                                       indicator = MissingIndicator()
                                       mask_missing_values_only = indicator.fit_transform(data_num_Rating)
                                      mask_missing_values_only
                                 □ array([[False],
                                               [False],
                                                Truel.
                                               [False],
                                               [False]])
                               [76] strategies=['mean', 'median', 'most_frequent']
                                     def test_num_impute(strategy_param):
                                         imp_num = SimpleImputer(strategy = strategy_param)
                                         data_num_imp = imp_num.fit_transform(data_num_Rating)
                                         return data_num_imp[mask_missing_values_only]
                               [77] strategies[0], test num impute(strategies[0])
                                C→ ('mean')
                                      array([4.19333832, 4.19333832, 4.19333832, ..., 4.19333832, 4.19333832,
                                              4.19333832]))
                               [78] strategies[1], test_num_impute(strategies[1])
                                ('median', array([4.3, 4.3, 4.3, ..., 4.3, 4.3, 4.3]))
                               [79] strategies[2], test_num_impute(strategies[2])
                                ('most_frequent', array([4.4, 4.4, 4.4, ..., 4.4, 4.4, 4.4]))
```

8.0

1.15

1.0

1.1.5

3.0 and up

4.1 and up

4.0 and up

4.0 and up

1.3 4.1 and up

2.0 2.3 and up

2.0.148.0 4.0 and up

```
4.193338
      mean
       std
               0.537431
      min
               1.000000
               4.000000
      50%
               4.300000
      75%
               4.500000
              19.000000
      max
[81] test_num_impute_col(data, 'Rating', strategies[0])
 ('Rating', 'mean', 1474, 4.193338315362443, 4.193338315362443)
[83] test_num_impute_col(data, 'Rating', strategies[1])
 ('Rating', 'median', 1474, 4.3, 4.3)
[84] test_num_impute_col(data, 'Rating', strategies[2])
```

('Rating', 'most_frequent', 1474, 4.4, 4.4)

4.2.2. Обработка пропусков в категориальных данных

```
[85] #Выберем категориальные колонки с пропущенными значениями
     #Цикл по колонкам датасета
     categ_cols = []
     for col in data.columns:
         temp_null_count = data [data[col].isnull()].shape[0]
         dt = str(data[col].dtype)
         if temp_null_count > 0 and (dt == 'object'):
             categ_cols.append(col)
              temp_perc = round((temp_null_count / total_count) * 100.0, 2)
              print('Колонка {}. Тип данных {}. Количество пустых значений {}, {}%'.format(col, dt, temp_null_count, temp_perc))
 С→ Колонка Туре. Тип данных object. Количество пустых значений 1, 0.01%
     Колонка Content Rating. Тип данных object. Количество пустых значений 1, 0.01% Колонка Current Ver. Тип данных object. Количество пустых значений 8, 0.07%
     Колонка Android Ver. Тип данных object. Количество пустых значений 3, 0.03%
[86] categ_temp_data = data[['Content Rating']]
     categ_temp_data.head()
 C→
         Content Rating
      0
                Everyone
                Everyone
      1
      2
                Everyone
      3
                    Teen
                Everyone
[87] categ_temp_data['Content Rating'].unique()
rray(['Everyone', 'Teen', 'Everyone 10+', 'Mature 17+', 'Adults only 18+', 'Unrated', nan], dtype=object)
[88] categ_temp_data[categ_temp_data['Content Rating'].isnull()].shape
[→ (1, 1)
                           [89] #импьютация наиболее частыми значениями
                                 imp2 = SimpleImputer(missing_values=np.nan, strategy='most_frequent')
                                 data_imp2 = imp2.fit_transform(categ_temp_data)
                                 data_imp2
                            □→ array([['Everyone'],
                                         ['Everyone'],
                                         ['Everyone'],
['Mature 17+'],
                                         ['Everyone']], dtype=object)
                           [90] np.unique(data_imp2)
                            rray(['Adults only 18+', 'Everyone', 'Everyone 10+', 'Mature 17+', 'Teen', 'Unrated'], dtype=object)
                           [91] #импьютация константой
                                imp3 = SimpleImputer(missing_values=np.nan, strategy='constant', fill_value='EA')
                                data_imp3 = imp3.fit_transform(categ_temp_data)
                                data_imp3
                            □→ array([['Everyone'],
                                       ['Everyone'],
['Everyone'],
                                        'Mature 17+'],
                                       ['Everyone']], dtype=object)
                           [92] np.unique(data imp3)
                            [93] data_imp3[data_imp3 == 'EA'].size
                            [→ 1
```

5. Преобразование категориальных признаков в числовые



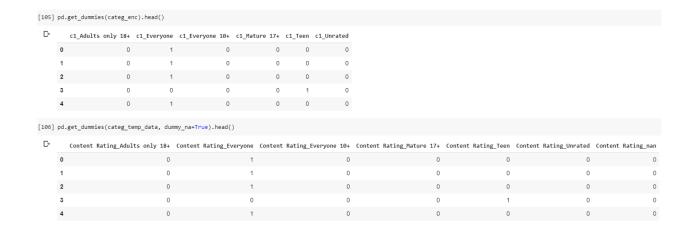
5.1. Кодирование категорий целочисленными значениями – label encoding

5.2. Кодирование категорий наборами бинарных значений — one-hot encoding

```
[99] ohe = OneHotEncoder()
    categ_enc_ohe = ohe.fit_transform(categ_enc[['c1']])
[100] categ_enc.shape
[> (10841, 1)
[101] categ_enc_ohe.shape
[> (10841, 6)
```

```
[102] categ_enc_ohe
 <10841x6 sparse matrix of type '<class 'numpy.float64'>'
             with 10841 stored elements in Compressed Sparse Row format>
[103] categ_enc_ohe.todense()[0:10]
 matrix([[0., 1., 0., 0., 0., 0.],
             [0., 1., 0., 0., 0., 0.],
             [0., 1., 0., 0., 0., 0.],
             [0., 0., 0., 0., 1., 0.],
             [0., 1., 0., 0., 0., 0.],
             [0., 1., 0., 0., 0., 0.],
             [0., 1., 0., 0., 0., 0.],
             [0., 1., 0., 0., 0., 0.],
             [0., 1., 0., 0., 0., 0.],
             [0., 1., 0., 0., 0., 0.]])
[104] categ_enc.head(10)
 \Box
               c1
      0 Everyone
         Everyone
         Everyone
      3
             Teen
         Everyone
         Everyone
         Everyone
         Everyone
         Everyone
         Everyone
```

5.3. Pandas_get_dummies – быстрый вариант one-hot кодирования



6. Масштабирование данных

6.1. МіпМах масштабирование

```
[107] from sklearn.preprocessing import MinMaxScaler, StandardScaler, Normalizer
[108] sc1 = MinMaxScaler()
    sc1_data = sc1.fit_transform(data[['Rating']])
```

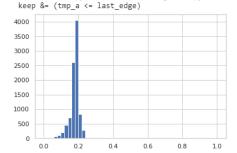
```
[109] plt.hist(data['Rating'], 50)
plt.show()
```

C> /usr/local/lib/python3.6/dist-packages/numpy/lib/histograms.py:839: RuntimeWarning: invalid value encountered in greater_equal
 keep = (tmp_a >= first_edge)
/usr/local/lib/python3.6/dist-packages/numpy/lib/histograms.py:840: RuntimeWarning: invalid value encountered in less_equal
 keep &= (tmp_a <= last_edge)</pre>

3000 2500 2000 1500 500 2.5 5.0 7.5 10.0 12.5 15.0 17.5

```
[110] plt.hist(sc1_data, 50)
plt.show()
```

//wsr/local/lib/python3.6/dist-packages/numpy/lib/histograms.py:839: RuntimeWarning: invalid value encountered in greater_equal
keep = (tmp_a >= first_edge)
//wsr/local/lib/python3.6/dist-packages/numpy/lib/histograms.py:840: RuntimeWarning: invalid value encountered in less_equal



6.2. Масштабирование данных на основе Z-оценки – StandardScaler

```
[112] sc2 = StandardScaler()
    sc2_data = sc2.fit_transform(data[['Rating']])

[111] plt.hist(sc2_data, 50)
    plt.show()
```

_ /usr/local/lib/python3.6/dist-packages/numpy/lib/histograms.py:839: RuntimeWarning: invalid value encountered in greater_equal
 keep = (tmp_a >= first_edge)
 /usr/local/lib/python3.6/dist-packages/numpy/lib/histograms.py:840: RuntimeWarning: invalid value encountered in less_equal
 keep &= (tmp_a <= last_edge)</pre>

